
Clustering no Dataset Iris

Comparando K-Means, Hierárquico e GMM • quando a forma dos grupos decide qual algoritmo vence

Thales de Souza Crivillari • Projeto de portfólio, Aprendizado Não Supervisionado • R, `set.seed(236312)`

Resumo. Este é um projeto didático que compara três famílias clássicas de *clustering* num conjunto de dados famoso e de fácil interpretação. A ideia é mostrar, de forma visual e passo a passo, por que algoritmos diferentes chegam a respostas diferentes, e por que um modelo probabilístico (GMM) lida melhor com grupos que se sobrepõem do que métodos baseados puramente em distância. Cada decisão de modelagem é explicada à medida que aparece, de modo que o texto sirva tanto para quem está aprendendo *clustering* quanto para quem quer ver o raciocínio por trás dos números.

1 Contexto

Clustering é a tarefa de agrupar observações parecidas sem saber de antemão a que grupo cada uma pertence. É aprendizado não supervisionado: o algoritmo não recebe rótulos, apenas as medidas, e precisa descobrir sozinho a estrutura. A pergunta natural é: será que ele descobre a estrutura “certa”?

O conjunto Iris é perfeito para responder isso, porque é um dos raros casos em que conhecemos a resposta. São 150 flores, 50 de cada uma de três espécies (*setosa*, *versicolor* e *virginica*), cada uma descrita por quatro medidas: comprimento e largura de sépala e de pétala. Como sabemos a espécie de cada flor, podemos rodar um algoritmo de *clustering* escondendo essa informação e depois conferir o quanto ele acertou.

Vale pensar no *clustering* como um teste cego: entregamos ao algoritmo só as medidas das flores e perguntamos quais delas formam grupos naturais. Depois levantamos o pano e comparamos os grupos que ele inventou com as espécies reais. Quanto mais parecidos, melhor o algoritmo capturou a estrutura dos dados.

Vamos comparar três métodos: K-Means, agrupamento hierárquico e GMM (modelo de mistura gaussiana), e medir o acerto de cada um com uma única métrica objetiva, o *Adjusted Rand Index*.

2 Análise exploratória

Antes de qualquer algoritmo, vale visualizar. A Figura 1 mostra todos os pares de variáveis, com as cores revelando a espécie real de cada flor (uma informação que os algoritmos não vão receber).



Figura 1. Cada quadro fora da diagonal é um gráfico de dispersão de duas variáveis; a diagonal mostra a densidade de cada medida por espécie; o triângulo superior traz as correlações. As cores são os rótulos verdadeiros.

Dois padrões organizam toda a análise daqui para frente:

1. *setosa* (azul) vive sozinha. Em qualquer gráfico que envolva pétalas, ela forma uma nuvem isolada, bem longe das outras duas. Esse é o caso fácil: qualquer algoritmo razoável vai separá-la sem dificuldade.
2. *versicolor* (vermelho) e *virginica* (verde) se misturam. Elas se encostam e até se sobrepõem, principalmente nas medidas de pétala. É aqui que os algoritmos vão se diferenciar: a fronteira entre essas duas espécies é difusa, e separá-las bem exige um método que entenda a forma de cada nuvem de pontos.

A imagem a guardar é essa: um grupo fácil e isolado (*setosa*) e dois grupos “grudados” e alongados (*versicolor* e *virginica*). O placar final vai depender quase inteiramente de quão bem cada método resolve a confusão entre esses dois últimos.

3 K-Means

3.1 Como funciona

O K-Means tenta dividir os dados em K grupos colocando K “centros” e atribuindo cada ponto ao centro mais próximo. Ele repete dois passos até estabilizar: (1) atribui cada ponto ao centro mais próximo; (2) recalcula cada centro como a média dos seus pontos. O resultado tende a formar bolhas redondas e de tamanho parecido, e essa é a suposição embutida no método, e também sua principal limitação.

3.2 Escolha de K

O K-Means precisa que digamos quantos grupos queremos. Dois diagnósticos clássicos ajudam a decidir (Figura 2):

- Método do cotovelo: mede o quão “apertados” ficam os grupos (soma das distâncias internas) para cada K . Procuramos o “cotovelo”, o ponto onde aumentar K deixa de compensar. Aqui ele aparece em $K = 3$.
- Silhueta: mede o quão bem separado cada ponto está do grupo vizinho. Curiosamente, ela prefere $K = 2$, ou seja, ela enxerga versicolor + virginica como um único grupo.




Figura 2. Dois critérios para escolher o número de grupos. O cotovelo sugere $K = 3$ (esquerda); a silhueta sugere $K = 2$ (direita).

Esse desacordo já é, em si, um resultado interessante. A silhueta “acha” que só há dois grupos bem separados porque, do ponto de vista de distância pura, versicolor e virginica realmente parecem um bloco só. É a primeira evidência de que a fronteira entre elas é fraca. Como sabemos que há três espécies, seguimos com $K = 3$ para poder comparar com a verdade.

3.3 Resultado com $K = 3$

A Figura 3 mostra os três grupos encontrados, projetados num plano que resume as quatro variáveis. A setosa sai perfeita; a divisão entre os outros dois é decente, mas erra na zona de mistura, exatamente como a silhueta antecipou.




Figura 3. Os três grupos do K-Means. As elipses são apenas auxílio visual; o método em si só conhece distâncias até os centros.

4 Agrupamento hierárquico

4.1 Como funciona

O agrupamento hierárquico não precisa que escolhamos K de antemão. Ele começa com cada flor sendo seu próprio grupo e vai fundindo os dois grupos mais parecidos, repetidamente, até sobrar um só. O histórico dessas fusões forma uma árvore, o dendrograma. Usamos o critério de Ward, que a cada passo funde os grupos que menos aumentam a variância interna.

A grande vantagem é o dendrograma: ele mostra a estrutura em todas as escalas de uma vez. Para obter K grupos, basta “cortar” a árvore na altura certa.




Figura 4. Dendrograma de Ward. A altura de cada fusão indica o quão diferentes eram os grupos unidos. Cortar a árvore em $K = 3$ produz os três ramos coloridos.

4.2 Lendo a árvore

A leitura é direta e conta a mesma história da EDA. O primeiro corte, lá no alto, separa o ramo azul (setosa) de todo o resto a uma altura enorme, isto é, a setosa é muito diferente das outras duas. Só bem mais embaixo, a uma altura menor, os outros dois ramos se separam, sinal de que versicolor e virginica são parecidas entre si. Cortando em três grupos, herdamos a mesma dificuldade do K-Means na fronteira.

A chave para ler a árvore é que altura significa dissimilaridade: fusões no alto unem coisas bem diferentes; fusões embaixo unem coisas parecidas. O fato de o galho da setosa só se juntar aos demais lá em cima é a versão em árvore daquela nuvem azul isolada que vimos na EDA.

5 GMM

5.1 Como funciona

Aqui muda a filosofia. Em vez de pensar em distâncias, o GMM assume que os dados foram gerados por uma mistura de várias distribuições normais (gaussianas), uma por grupo. O algoritmo estima, para cada gaussiana, onde está seu centro e qual o seu formato, ou seja, sua matriz de covariância. Por isso cada grupo pode ser uma elipse esticada e girada do jeito que melhor encaixar nos dados, em vez de uma bolha redonda.

Outra diferença: o GMM dá uma atribuição probabilística. Cada ponto tem uma probabilidade de pertencer a cada grupo, o que é especialmente útil na zona de fronteira onde a resposta é genuinamente incerta.

A diferença essencial está na pergunta que cada método faz. O K-Means só sabe perguntar qual centro está mais perto; o GMM pergunta qual gaussiana, com seu formato próprio, mais provavelmente gerou aquele ponto. Essa liberdade de formato é exatamente o que falta aos outros dois métodos para separar duas nuvens alongadas e sobrepostas.

5.2 Seleção automática via BIC

O pacote `mclust` consegue escolher sozinho o melhor número de grupos e o melhor tipo de formato, usando um critério chamado BIC (que premia bom ajuste e penaliza complexidade excessiva). A Figura 5 mostra esse processo: cada curva é um tipo de formato de covariância, e o eixo horizontal é o número de grupos.




Figura 5. Seleção automática via BIC. No `mclust` vale o contrário da convenção usual: quanto mais alto, melhor. O ponto mais alto fica em 2 grupos, com 3 logo atrás.

Quando deixamos o BIC escolher sozinho, ele aponta para 2 grupos: lê o par versicolor + virginica, por serem tão sobrepostos, como um aglomerado só, e separa apenas a setosa do resto. Mas há um detalhe importante na figura. O valor de BIC em 2 e em 3 grupos fica praticamente empatado: a curva sobe forte de 1 para 2 e, de 2 para 3, mal se move. Em outras palavras, a evidência que faz o critério parar em 2 em vez de 3 é muito fraca.

E aqui entra uma pergunta razoável: por que confiar no BIC, e não em outro critério? Existem alternativas conhecidas, como o AIC, que seguem a mesma ideia de “ajuste menos penalidade pela complexidade”, mas cobram a penalidade de forma diferente. O BIC pune cada parâmetro extra na proporção de $\ln(n)$, que para as 150 flores vale cerca de 5; o AIC pune com um valor fixo de 2, ou seja, penaliza muito menos a complexidade.

Essa diferença na penalidade tem consequência direta: como o BIC pune mais a complexidade, ele tende a escolher menos grupos, enquanto o AIC, mais permissivo, quase certamente escolheria 3 (ou mais). Nenhum está errado; eles respondem a perguntas diferentes. O BIC busca o número verdadeiro de grupos, enquanto o AIC busca o que prevê melhor dados novos. Aqui usamos o BIC simplesmente porque é o critério que já vem por padrão no `mclust` e o que a função de seleção automática emprega. Vale notar, porém, que a distância entre 2 e 3 grupos é mínima: o próprio empate já sugere que três grupos são perfeitamente plausíveis.

Junte isso a duas outras evidências que já vimos: o método do cotovelo do K-Means também apontou 3 e, o mais decisivo, nós sabemos que existem 3 espécies. Quando vários sinais independentes convergem para 3 e o único que hesita (o BIC) o faz por uma margem desprezível, a leitura mais honesta não é “os dados só têm 2 grupos”, e sim: a terceira divisão é real, só é sutil. O BIC simplesmente não a considerou forte o bastante para declará-la sozinho.

5.3 Ajuste com $K = 3$

Como os outros dois métodos rodaram com três grupos, e como a própria estrutura do problema aponta para três espécies, reajustamos o GMM também com três (Figura 6). Recuperada a terceira divisão que o BIC tinha deixado de lado por pouco, o GMM separa versicolor e virginica muito melhor que os métodos de distância, porque suas elipses acompanham o formato real e inclinado das nuvens.




Figura 6. Classificação final do GMM com 3 grupos. A incerteza se concentra em pouquíssimas flores na fronteira entre as duas espécies parecidas.

6 Adjusted Rand Index

6.1 A métrica

Não basta olhar os gráficos; precisamos de um número. Usamos o Adjusted Rand Index (ARI), que mede o quanto a divisão em grupos feita pelo algoritmo coincide com as espécies reais. Ele compara as duas classificações par a par: quanto mais elas concordam sobre quais flores ficam juntas e quais ficam separadas, maior o ARI. O ajuste no nome vem de um desconto que o índice aplica para que acertos obtidos por puro acaso não influem o resultado.

- $ARI = 1$: partição idêntica à verdade (acerto perfeito).
- $ARI \approx 0$: tão bom quanto agrupar aleatoriamente.

6.2 Cálculo

A base do ARI é a comparação par a par. Com $n = 150$ flores, há $\binom{150}{2} = 11.175$ pares possíveis, e para cada par perguntamos se as duas classificações concordam: o par está junto (mesmo grupo) ou separado nas duas? A versão mais simples dessa ideia, o Rand Index, é apenas a fração de pares em que há concordância. O problema é que, mesmo agrupando ao acaso, muitos pares coincidem por sorte (sobretudo os “separados”, já que com vários grupos a maioria dos pares naturalmente cai em grupos distintos). O Rand Index, portanto, quase nunca chega perto de zero, o que o torna pouco informativo.

O ARI corrige isso descontando exatamente esse acerto esperado pelo acaso. A estrutura geral é:

$$\text{ARI} = \frac{\text{índice observado} - \text{índice esperado por acaso}}{\text{índice máximo} - \text{índice esperado por acaso}}.$$

Com isso, um agrupamento equivalente ao acaso zera o numerador ($\text{ARI} = 0$), um agrupamento idêntico à verdade dá $\text{ARI} = 1$, e um agrupamento pior que o acaso pode ficar negativo, algo que o Rand Index original nunca permite.

Na prática, o cálculo parte da tabela de contingência que cruza os grupos do algoritmo com as espécies reais, onde n_{ij} é o número de flores na linha i e coluna j , com totais de linha a_i e de coluna b_j . A forma fechada (Hubert & Arabie, 1985) é:

$$\text{ARI} = \frac{\sum_{ij} \binom{n_{ij}}{2} - \frac{[\sum_i \binom{a_i}{2}] [\sum_j \binom{b_j}{2}]}{\binom{n}{2}}}{\frac{1}{2} \left[\sum_i \binom{a_i}{2} + \sum_j \binom{b_j}{2} \right] - \frac{[\sum_i \binom{a_i}{2}] [\sum_j \binom{b_j}{2}]}{\binom{n}{2}}}.$$

O primeiro termo do numerador conta os pares que realmente ficaram juntos em ambas as classificações; o termo subtraído é o número de coincidências que se esperaria por acaso, dado apenas o tamanho de cada grupo. No R, todo esse cálculo está embutido na função `adjustedRandIndex(grupos, espécies)` do pacote `mclust`.

6.3 Resultado

Tabela 1. Concordância de cada método com as espécies reais (semente 236312).

Método	ARI
Hierárquico (Ward)	0,615
K-Means ($K = 3$)	0,620
GMM ($K = 3$)	0,904




Figura 7. O placar final. O GMM supera os métodos de distância por uma margem larga e clara.

A diferença é grande e tem uma explicação única. K-Means e o corte hierárquico empatam em torno de 0,62 porque esbarram no mesmo obstáculo: ambos assumem grupos redondos e separam por distância, então tropeçam na mesma região de mistura entre versicolor e virginica. O GMM chega a 0,90 porque a única coisa que os outros não têm é justamente o que essa fronteira exige: a capacidade de moldar cada grupo a um formato próprio.

A Tabela 2 mostra de onde vêm os acertos e os poucos erros do GMM: das 150 flores, apenas 5 versicolor são confundidas com virginica.

Tabela 2. Matriz de confusão do GMM. Linhas são os grupos encontrados; colunas, as espécies reais. O ideal seria todo o “peso” na diagonal.

	<i>setosa</i>	<i>versicolor</i>	<i>virginica</i>
Grupo 1	50	0	0
Grupo 2	0	45	0
Grupo 3	0	5	50

7 Conclusão

1. *Não existe um melhor algoritmo de clustering em abstrato.* O melhor depende do formato dos grupos. Quando eles são redondos e separados, K-Means basta; quando são alongados e sobrepostos, um modelo que aprende formato (GMM) ganha.
2. Sempre visualize antes. Toda a história do placar estava visível na EDA: o grupo fácil e os dois grupos grudados. O número final só confirmou o que os gráficos já sugeriam.
3. Critérios não são oráculos; pesam evidências. O BIC parou em 2 grupos, mas por uma margem mínima sobre 3, enquanto o cotovelo e a verdade conhecida apontavam 3. A lição não é “o BIC errou”, e sim que a escolha de um critério embute uma postura (o BIC é conservador, o AIC é permissivo) e que, quando os números ficam empatados, vale cruzar várias evidências em vez de obedecer cegamente a um só.

Reprodutibilidade. Tudo aqui é gerado pelo script `clustering_iris.R` com `set.seed(236312)`. As figuras são salvas na pasta `figs/` e este PDF é compilado a partir de `relatorio.tex`. Pacotes: `mclust`, `factoextra`, `dendextend`, `cluster`, `GGally`, `ggplot2`.